

DeepSeek-V4

1M 컨텍스트를 '실용 비용'으로 만든 시스템 설계

아키텍처 · 수식 · GRPO/OPD · 성능 · 비판적 검토 · 예상 질문

한 장 요약: V4의 기여는 '1M 지원'보다 비용 구조의 재설계다

1M

기본 컨텍스트

CSA + HCA가 KV를 시간축으로 압축하고, 필요한 블록만 읽는다.

27% / 10%

Pro의 FLOPs / KV

1M에서 V3.2 대비 추정 FLOPs 27%, KV cache 10%.

GRPO → OPD

전문화 후 통합

도메인별 전문가를 RL로 키우고, 학생 궤적에서 reverse KL로 하나의 모델에 증류.

발표 결론

엔지니어링 증거는 강하지만, 구성요소별 인과를 가르는 ablation과 데이터·학습비용 투명성은 부족하다.

긴 컨텍스트의 병목: 계산은 제곱, KV는 선형으로 증가한다

Vanilla attention

Attention FLOPs $\approx O(n^2d)$

KV cache $\approx O(nd)$



n이 10배가 되면 attention 계산은 약 100배가 된다. 추론 단계에서는 매 토큰마다 긴 과거를 다시 조회해야 한다.

V4의 답: '모든 토큰을 같은 해상도로 보지 않는다'

압축

희소 선택

로컬 창

CSA: 중간 압축 + top-k 검색

HCA: 강한 압축 + dense 조회

SWA: 최근 128토큰의 세밀한 정보 보존

Flash와 Pro는 같은 설계 철학을 서로 다른 용량·top-k로 구현한다

DeepSeek-V4-Flash

284B

전체 파라미터

13B

토큰당 활성

43 layers · hidden 4096
CSA top-k 512 · 64 query heads
32T tokens · FP4 MoE + FP8 mixed

DeepSeek-V4-Pro

1.6T

전체 파라미터


49B

토큰당 활성

61 layers · hidden 7168
CSA top-k 1024 · 128 query heads
33T tokens · FP4 MoE + FP8 mixed


공통: 1 shared + 256/384 routed experts, 토큰당 routed expert 6개, mHC expansion 4, SWA 128

V4 블록은 압축 attention, MoE, 강화된 residual을 결합한다



핵심: 어느 한 기술의 승리가 아니라, 모델 구조와 커널·캐시·정밀도를 함께 설계했다.

CSA: 4개 토큰을 1개 KV로 압축한 뒤, 관련 블록 top-k만 조회한다



압축식(발표용 단순화)

$$C_{comp,i} = \sum_j S_j \odot C_j$$

$$S = \text{softmax}(Z + \text{positional bias})$$

Lightning Indexer

$$I(t,s) = \sum_h w(t,h) \cdot \text{ReLU}(q(t,h) \cdot K_s)$$

각 query가 관련 압축 블록을 빠르게 랭킹

정보 손실을 줄이는 3개의 안전장치

- ① 두 이웃 블록을 겹쳐 압축
- ② 최근 128토큰은 uncompressed sliding window
- ③ attention sink로 '아무 데도 주지 않는' 질량 허용

HCA: 128:1 압축 후 요약 전체를 dense 조회한다

1. Heavier compression

$$m' = 128$$

1M 토큰 → 약 7,813개의
압축 KV entry

$$C_{\text{comp},i} = \sum_j S_j \odot C_j$$

2. Dense over summaries

top-k 없음

압축된 전역 요약은 모두 조회
→ 전역 혼합을 매우 싸게 유지

$$\text{CoreAttn}(q, C_{\text{comp}}, C_{\text{comp}})$$

3. Hybrid interleaving


CSA ↔ HCA

CSA는 선택적 고해상도
HCA는 저비용 전역 전달

첫 2개 layer: Pro=HCA, Flash=SWA

왜 둘 다? CSA만 쓰면 전역 연결이 top-k에 갇히고, HCA만 쓰면 세밀한 검색 해상도가 부족하다.

1M 컨텍스트에서 Pro는 V3.2의 27% FLOPs, 10% KV cache를 주장한다



해석 1

Flash는 active params도 작아 FLOPs가 10%까지 내려간다.

해석 2

KV 절감은 압축 + FP8/BF16 혼합 저장의 합산 효과다.

주의

wall-clock latency 27%라는 뜻은 아니다. 통신·I/O·routing·hardware가 남는다.

mHC와 Muon은 대형 MoE 학습의 안정성을 말한다

mHC: residual stream의 폭을 늘리되 폭 주를 막는다

$$X_{l+1} = B_l X_l + C_l F_l(A_l X_l)$$

$$B_l \mathbf{1} = \mathbf{1}, \quad \mathbf{1}^T B_l = \mathbf{1}^T, \quad B_l \geq 0$$

$$\Rightarrow \|B_l\|_2 \leq 1$$

B_l 을 doubly stochastic manifold에 투영한다. 신호가 layer를 지날 때 폭증하지 않는 non-expansive mapping이 된다.

Muon: gradient matrix를 '방향 정돈' 후 업데이트


$$M_t = \mu M_{(t-1)} + G_t$$

$$O'_t \approx U V^T \quad \text{via Newton-Schulz}$$

$$W_t = (1 - \eta\lambda)W_{(t-1)} - \eta O_t$$

대부분의 2D weight는 Muon. embedding, head, RMSNorm, 일부 mHC 파라미터는 AdamW. 8+2 hybrid Newton-Schulz iteration.

사전학습은 4K에서 시작해 1M까지 늘리는 길이·희소성 커리큘럼이다



데이터

Flash 32T · Pro 33T
수학·코드·웹·장문·다국어


희소성

초기 1T token은 dense
64K부터 sparse 유지

안정화

Anticipatory Routing
SwiGLU clamp $[-10, 10]$

Post-training은 '전문가를 따로 키우고, 학생 하나로 다시 합치는' 2단계다



핵심 분리

GRPO는 능력을 '발견·강화'하고, OPD는 전문가 간 간섭 없이 능력을 '통합'한다.

GRPO: critic 없이 같은 문제의 답들을 상대 평가한다

① 하나의 prompt q 에서 G 개 응답 생성

$o_1, o_2, \dots, o_G \sim \pi_{\text{old}}(\cdot | q)$

② reward를 그룹 내 표준화

$A_i = (r_i - \text{mean}(r)) / (\text{std}(r) + \epsilon)$

③ PPO식 clipped update + KL

critic/value model 불필요

$$J_{\text{GRPO}}(\theta) = E \left[\frac{1}{G} \sum_i \min(\rho_i A_i, \text{clip}(\rho_i, 1-\epsilon, 1+\epsilon) A_i) - \beta \text{KL}(\pi_\theta || \pi_{\text{ref}}) \right]$$

$\rho_i = \pi_\theta(o_i | q) / \pi_{\text{old}}(o_i | q)$ · 실제 구현은 token-level objective

장점

critic 메모리 제거
LLM RL 확장에 유리

직관

같은 난도의 문제 안에서
평균보다 좋은 답을 강화

취약점

보상이 모두 같으면 신호 0
reward hacking 가능

보상은 '검증 가능한가'에 따라 rule/test와 Generative Reward Model로 나뉜다

검증 가능

수학 정답 · 코드 테스트 · tool schema

- rule-based verifier
- unit / integration test
- 형식·파서 성공 여부
- 환경에서 실제 실행 결과

신호가 객관적이고 reward hacking을 찾기 쉽다.

검증 어려움

글쓰기 · 복합 판단 · 장기 agent trajectory

- rubric-guided RL data
- GRM이 trajectory를 생성형으로 평가
- actor 자체를 GRM으로도 최적화
- 적은 human annotation으로 일반화

자기평가 편향·공모(collusion)·확증 편향 위험은 남는다.

리뷰 포인트: GRM이 좋아졌다는 주장은 있으나, V4 보고서에는 보상모델 ablation과 calibration 결과가 충분하지 않다.

OPD: 학생 궤적에서 전문가의 전체 logit을 따라간다

$$L_{OPD}(\theta) = \sum_i w_i \cdot D_{KL}(\pi_\theta \parallel \pi_{Ei}), \quad \text{trajectory } y \sim \pi_\theta$$

학생이 실제로 방문한 상태에서 teacher를 묻기 때문에 on-policy

왜 reverse KL?

$E_{y \sim \pi_\theta} [\log \pi_\theta - \log \pi_E]$
학생이 내는 답의 분포를
전문가의 고확률 영역으로 이동

왜 full vocabulary?


샘플된 token 하나의 log-ratio가 아니라
매 위치의 전체 vocab logits를 사용
→ 낮은 분산, 안정적 gradient

왜 multi-teacher?

>10 experts: math · code · agent
· instruction
context에 맞는 teacher weight w_i
→ 물리적으로 분리된 능력을 통합

논문의 주장: weight merging-mixed RL에서 생기는 전문가 간 간섭을 logits 수준 정렬로 우회한다.

Reasoning effort가 어려운 추론·장문 검색 성능을 좌우한다



GPQA

72.9 → 90.1

HLE

7.7 → 37.7

MRCR 1M

44.7 → 83.5

V4는 open-weight 최상위지만 frontier를 모두 넘지는 못했다

V4-Pro-Max와 가장 높은 비교 모델

벤치마크	V4-Pro-Max	최고 비교 모델	읽을 점
MMLU-Pro	87.5	Gemini 91.0	교육 지식은 frontier 미달
SimpleQA	57.9	Gemini 75.6	세계 지식 격차가 큼
GPQA Diamond	90.1	Gemini 94.3	상위권이나 1위 아님
LiveCodeBench	93.5	Gemini 91.7	v4가 비교군 최고
MRCR 1M	83.5	Opus 92.9	1M retrieval은 강하나 열세
Terminal Bench	67.9	GPT-5.4 75.1	agent는 closed가 앞섬
SWE Verified	80.6	Opus 80.8	사실상 동률
Toolathlon	51.8	GPT-5.4 54.6	tool 일반화는 경쟁력

비판적 검토: 시스템은 강하지만 인과 증거는 약하다

강한 점

- 1M을 구조·커널·KV·정밀도까지 공동 설계
- Flash/Pro 두 규모와 공개 weight·inference code
- RL 전문화와 multi-teacher OPD의 명확한 분리
- 58쪽에 학습·인프라·배포 세부가 풍부

논문 자체 한계: preview · multimodal 부재 · stability 원리 미해명

약한 점 / 질문

- CSA/HCA/mHC/Muon/데이터의 개별 ablation 부족
- 학습 compute·hardware·에너지·총비용 미공개
- 32–33T 데이터 구성·오염 검증의 투명성 제한
- 일부 비교는 내부 harness·실패한 API·상이한 budget
- MRCR는 128K 이후 하락, '1M=동일 품질' 아님

예상 질문 ① — 구조와 효율

Q1

**1M이면 정말 1M을
'이해'하나?**

지원과 품질은 다르다. MRCR는 128K 이후 하락하지만 Pro-Max는 1M에서도 비교군 대비 경쟁력이 있다.

**한 줄 답: 'usable 1M'이지
'lossless 1M'은 아니다.**

Q2

**CSA와 HCA를 왜
둘 다 쓰나?**

CSA는 query별 top-k로 세밀한 관련 블록을 찾고, HCA는 128:1 압축으로 값싼 전역 mixing을 보장한다.

한 줄 답: 검색 해상도와 전역 연결의 trade-off.

Q3

**FLOPs 27%면
latency도 27%인가?**

아니다. single-token equivalent FP8 FLOPs 추정치다. 실제 지연에는 통신, KV I/O, routing, batch, kernel 효율이 포함된다.

**한 줄 답: 계산량 지표이지
wall-clock 보장은 아니다.**

예상 질문 ② — RL, OPD, 재현성

Q4

**GRPO는 PPO보다
무조건 좋은가?**

critic을 제거해 메모리는 줄지만
, group reward variance와
verifier 품질에 민감하다. 모든
reward가 같으면 학습 신호가
약해진다.

**답: 확장성 trade-off이지 보편적
우월성이 아니다.**

Q5

**왜 마지막에 RL 대신
OPD를 쓰나?**

mixed RL은 도메인 reward 간
간섭이 생길 수 있다. OPD는 각
expert의 logit 분포를 학생
parameter space로 통합한다.

**답: 능력 발견은 RL, 능력 합치기
는 distillation.**

Q6

논문은 재현 가능한가?

weight·inference code는 공개
되지만 32–33T 데이터, 전체
compute, 내부 평가 harness와
teacher routing은 완전 공개가
아니다.

**답: inference는 높음,
end-to-end training은 제한적.**

최종 판단: 시스템 혁신은 강하고, 인과 규명은 남았다

TAKEAWAY

DeepSeek-V4는 1M context를
비용·메모리·학습 안정성까지 포함해
하나의 제품 수준 시스템으로 만든 보고서다.

발표 후 기억할 3가지

① CSA/HCA = 압축 + 선택 + 로컬
보존

② GRPO = 전문가 강화 · OPD = 전문
가 통합

③ 1M support ≠ 1M lossless
quality