

QeRL

양자화가 강화학습의 탐색을 도울 수 있을까?

Beyond Efficiency: Quantization-enhanced
Reinforcement Learning for LLMs

Wei Huang 외 · NVIDIA, MIT, HKU, THU · 2025



QeRL을 이루는 세 가지 동작

기본 모델은 Qwen2.5-Instruct입니다. 아래 동작을 조합해 수학 문제 풀이를 강화학습합니다.

구성 요소	실제로 하는 일
NVFP4	기본 가중치를 4비트로 저장해 메모리와 생성 비용을 줄입니다.
LoRA	기본 가중치는 고정하고, 작은 추가 행렬만 보상에 따라 갱신합니다.
AQN	모델 내부에 작은 잡음을 더하고 그 세기를 조절해 풀이 탐색을 돕습니다.

QeRL은 NVFP4와 LoRA를 결합합니다.

QeRL + AQN은 이 구성에 탐색용 잡음 조절을 추가한 설정입니다.

실험의 출발점, Qwen2.5-Instruct

범용 지시학습 모델에서 시작해, 모델 크기와 학습 방식에 따른 차이를 봅니다.

기본 모델	GSM8K 학습	BigMath 학습
Qwen2.5-3B-Instruct	GRPO	미보고
Qwen2.5-7B-Instruct	GRPO	DAPO
Qwen2.5-14B-Instruct	미보고	DAPO
Qwen2.5-32B-Instruct	미보고	DAPO

공통 LoRA rank는 32입니다.

정확도 실험은 H100 8장, 속도 실험은 H100 1장으로 진행했습니다. B는 파라미터 10억 개를 뜻합니다.

같은 모델에 여섯 가지 학습 방식을 적용한다

Full과 LoRA는 갱신 범위가 다르고, NF4·MXFP4·NVFP4는 저장 형식이 다릅니다.

학습 구성	기본 가중치	갱신 대상	비교하려는 요소
전체 학습 (Full)	BF16	전체 가중치	정확도 기준선
LoRA	BF16	어댑터	적은 파라미터로 학습
QLoRA	NF4	어댑터	4비트 압축 기준선
MXFP4 LoRA	MXFP4	어댑터	4비트 표현 형식의 차이
QeRL	NVFP4	어댑터	NVFP4의 표현과 커널
QeRL + AQN	NVFP4	어댑터	잡음 조절을 통한 탐색

모델의 이름과, 그 모델을 학습하는 방식을 구분해서 읽습니다.

답안을 만들고, 보상을 얻고, 정책을 바꾼다

정책은 다음 토큰을 고르는 확률 분포입니다. 보상이 높은 답안을 더 자주 생성하도록 바꿉니다.

01

답안 생성

같은 수학 문제에 여러 풀이를 생성합니다. 이 생성 과정을 롤아웃이라고 부릅니다.

02

보상 계산

최종 답을 확인합니다. 설명용 예로 6×7 의 답이 42면 1, 다르면 0을 줍니다.

03

정책 갱신

보상이 더 높은 답안을 더 자주 생성하도록 모델의 파라미터를 학습합니다.

탐색할 답안이 다양해야, 더 좋은 풀이를 발견할 기회도 생깁니다.

GRPO는 같은 문제의 답안끼리 비교한다

이점(advantage)은 “이 답안이 같은 묶음의 평균보다 얼마나 좋은가”를 나타냅니다.

후보 답안	정답 여부	보상 r	상대적 이점 A
풀이 A	정답	1	+1
풀이 B	오답	0	-1
풀이 C	정답	1	+1
풀이 D	오답	0	-1

$A = (\text{보상} - \text{평균 보상}) / \text{보상의 표준편차}$

표의 보상과 이점은 설명용 예시입니다. 같은 보상만 나오는 묶음에서는 유용한 학습 신호를 얻기 어렵습니다.

LoRA는 작은 행렬로 가중치 보정값을 학습한다

한 선형층에서 입력 x 를 출력 y 로 바꾸는 식입니다. 입력은 열벡터로 통일합니다.

$$y = (W + sBA)x = Wx + sB(Ax)$$

원래 가중치 W 는 고정합니다

입력 x 에 기본 모델의 계산을 그대로 적용합니다. 생성할 때도 큰 행렬 W 를 계속 읽습니다.

작은 행렬 A 와 B 를 학습합니다

A 는 입력을 r 차원으로 줄이고, B 는 출력 차원으로 되돌립니다. 보상에 따라 이 보정값을 갱신합니다.

W $m \times d$

A $r \times d$

B $m \times r$

$s = \alpha/r$ 보정 배율

d : 입력 차원 · m : 출력 차원 · r : 작은 중간 차원

학습할 파라미터 수는 md 개에서 $r(d + m)$ 개로 줄어듭니다.

예: $d = m = 4,096$, $r = 32$ 이면 한 선형층에서 1,677만 개 대신 약 26만 개를 학습합니다.

NVFP4는 작은 값과 공통 배율을 저장한다

정밀한 수를 매번 저장하는 대신, 작은 수와 공유하는 배율로 가중치를 표현합니다.

구성	저장 형식	역할
가중치 값	FP4, E2M1	낮은 비트 수로 값의 형태를 저장
16개 가중치의 공통 배율	FP8, E4M3	블록마다 값의 범위를 조정
텐서 전체의 배율	FP32	전체 크기를 한 번 더 조정

복원 가중치 = 전체 배율 × 블록 배율 × FP4 값

양자화 오차는 복원 가중치와 원래 가중치의 차이입니다.

같은 4비트인데 왜 속도가 다를까?

모델: Qwen2.5-7B-Instruct

조건: H100 80GB 1장, 배치 2. GRPO의 총 학습 속도를 비교합니다.

방법	모델 크기	총 학습 속도
LoRA	15.2 GB	1.0배
QLoRA	5.7 GB	0.8배
QeRL	5.9 GB	1.5배

NF4: 코드에서 값으로 복원

값의 표를 찾아 복원하는 처리 비용이 이 구현에서는 생성 속도를 낮췄습니다.

NVFP4: 최적화된 연산 경로

FP4 값과 배율을 처리하는 Marlin 커널을 활용해 생성 비용을 줄입니다.

더 작게 저장하는 것만으로는 속도를 설명할 수 없습니다.

속도는 저장 형식과 커널 구현, 하드웨어 조건이 함께 결정합니다.

압축, 어댑터 학습, 탐색 조절을 하나로

NVFP4로 기본 가중치를 저장하고, LoRA로 학습하며, AQN으로 탐색을 조절합니다.





Figure 2. LoRA, QLoRA, QeRL의 전체 구조

기본 가중치는 4비트로 저장하고, LoRA는 높은 정밀도로 갱신합니다.

오차가 다른 풀이를 시도할 여지를 만든다

로짓은 확률로 바꾸기 전의 점수입니다. 양자화 오차가 이 점수를 바꿀 수 있습니다.

다음 토큰 후보의 확률 · 설명용 가상 분포



설명용 계산 · 실험 수치 아님

엔트로피 H

1.03

다른 후보를 시도할 여지가 커집니다. 그 후보 중 정답이 있어야 정확도 향상으로 이어질 수 있습니다.

핵심은 다양한 시도 중에서 높은 보상을 얻는 출력을 학습하는 것입니다.

양자화 모델에서 더 높은 엔트로피를 관측했다

모델: Qwen2.5-7B-Instruct

학습: GSM8K + GRPO. 그래프는 학습 중 다음 토큰 분포의 엔트로피입니다.




Figure 5. 학습 단계에 따른 정책 엔트로피

관측

NVFP4의 엔트로피가 BF16 LoRA보다 높게 나타납니다.

논문의 해석

더 넓은 풀이 탐색이 보상 개선에 기여했을 수 있습니다.

엔트로피 곡선과 최종 정확도를 함께 봐야 학습 효과를 판단할 수 있습니다.

다양한 답안이 정확도로 이어지려면

다른 풀이를 시도했을 때 유효한 정답 후보가 늘어나야, 보상 차이로부터 학습할 수 있습니다.

단계	무슨 변화가 생기나	학습에 도움이 되는 조건
1 출력 점수 변화	양자화 오차가 로짓에 영향	의미 있는 후보의 선택 확률이 변함
2 풀이 탐색	다른 토큰과 풀이를 생성	기존에 드물던 정답 경로를 발견
3 보상 차이	답안마다 다른 보상을 받음	좋은 답안과 나쁜 답안을 구분
4 어댑터 갱신	좋은 답안의 생성 확률을 높임	학습한 변화가 평가 문제에도 유효

다양한 오답만 늘어난다면, 엔트로피가 높아져도 정확도는 좋아지지 않습니다.

이 연결은 논문의 관측을 설명하는 해석이며, 모든 인과 고리를 따로 검증한 실험은 아닙니다.

AQN은 정규화 배율에 작은 잡음을 더한다

AQN은 평소 덜 선택하던 풀이를 시도하도록, 모델 내부 계산에 작은 무작위 변화를 주는 장치입니다.

기존 RMSNorm $h = w \odot u(x)$

AQN을 켜면 $h_k = (w + z_k) \odot u(x)$

잡음의 분포 $z_{k,j} \sim N(0, \sigma_k^2)$
매 순전파마다 새로 뽑습니다. k는 잡음 크기를 정하는 학습 구간입니다.

$$u(x) = \frac{x}{\sqrt{\frac{1}{d} \sum_{j=1}^d x_j^2 + \delta}}$$

d: 채널 수 · δ : 0으로 나누는 것을 막는 작은 상수 · $\odot$: 같은 위치끼리 곱하기

Adaptive Quantization Noise

같은 입력도 조금 다르게 계산하게 합니다.

w 는 RMSNorm의 채널별 배율입니다. 여기에 작은 무작위 벡터 z 를 더해 다음 토큰의 점수에 영향을 줍니다.


σ 는 잡음의 표준편차입니다. 클수록 배율이 더 크게 흔들립니다.

잡음 자체를 보상으로 학습하지는 않습니다. 보상에 따른 업데이트는 LoRA의 A와 B에 남습니다.

잡음의 크기는 학습 단계에 따라 줄어든다

첫 구간에는 추가 잡음이 없습니다. 이후 잡음을 켜고, 정해 둔 일정에 따라 강도를 낮춥니다.

$$\sigma(k) = \sigma_{\text{start}} \cdot \left(\frac{\sigma_{\text{end}}}{\sigma_{\text{start}}} \right)^{\frac{k-1}{K-1}} \quad k = 1, \dots, K \text{의 감소 구간} \cdot \sigma_{\text{start}} = 0.01 \cdot \sigma_{\text{end}} = 0.0005$$



K = 10으로 재구성한 예시입니다. 초기 $\sigma = 0$ 구간은 그래프 앞에 별도로 둡니다.

현재 추가 잡음의 표준편차

0.0100

추가 잡음을 켜 초기 구간입니다. 다른 풀이를 탐색할 여지를 넓힙니다.

'Adaptive'는 여기서 정해 둔 학습 단계에 따라 강도를 조절한다는 뜻입니다. 보상이 낮을 때 자동으로 잡음을 키우는 피드백 제어는 아닙니다.

입력을 흔들면 가중치를 흔든 것과 같아진다

14장의 RMSNorm 식을 다시 정리한 결과입니다. 여기서는 입력을 열벡터로 씁니다.

입력의 변화

$$h_k = D_k h$$

채널별 배율

$$D_k = \text{diag}(1 + z_k \oslash w)$$

뒤따르는 선형층

$$y = \hat{W} h_k = (\hat{W} D_k) h$$

가중치에 곱한 것과 같은 효과입니다.

입력 채널 j 를 1.01배 하면, 그 입력을 받는 가중치의 열도 1.01배 한 것과 같습니다.

한 채널의 예

$$w_j = 1, z_j = 0.01$$

$$h_{k,j} = 1.01 h_j$$

$\oslash$ 는 원소별 나눗셈입니다. diag 는 벡터를 대각행렬로 만듭니다. 이 등가식은 $w_j \neq 0$ 인 채널에서 성립합니다.

실제 계산은 RMSNorm의 배율만 바꾸므로 4비트 저장과 연산 경로를 유지합니다.

Attention의 Q·K·V는 잡음을 공유하고, FFN의 gate-up은 또 다른 잡음을 공유합니다.

LoRA의 학습과 AQN의 탐색을 함께 쓰면

LoRA는 학습할 파라미터를 정하고, AQN은 학습 중 계산에 들어가는 잡음을 조절합니다.

BF16 LoRA

$$y = (W + sBA)h$$

기본 가중치 W는 고정하고, 보상으로 A와 B를 학습합니다.

QeRL

$$y = (\hat{W} + sBA)h$$

기본 가중치를 NVFP4로 저장합니다. $\hat{W}$ 는 그 복원값을 뜻합니다.

QeRL + AQN

$$y = (\hat{W} + sBA)D_kh$$

RMSNorm에서 바뀐 입력 D_kh 가 기본 분기와 LoRA 분기에 들어갑니다.

LoRA의 sBA

보상에 따라 학습하고 저장하는 보정값

AQN의 D_k

매 순전파마다 새로 뽑는 일시적 입력 변화

h 는 원래 RMSNorm 출력입니다. 정규화 직후 한 선형층의 비교식이며, 바이어스와 LoRA dropout은 생략했습니다.

QeRL 적용 전후, 무엇이 달라졌나?

모델: Qwen2.5-3B-Instruct, Qwen2.5-7B-Instruct

학습: GSM8K + GRPO. 평가: GSM8K 정답률(%). 같은 크기의 모델끼리 비교합니다.

조건	3B	7B
원래 BF16 모델, RL 전	61.2	76.3
NVFP4 양자화 후, RL 전	59.4	73.4
QeRL + AQN으로 RL 후	83.7	90.8
양자화 모델의 학습 전후 변화	+24.3%p	+17.4%p

이 증가분에는 강화학습 자체의 효과도 포함됩니다.

QeRL의 이점을 알려면, 같은 모델을 다른 방식으로 강화학습한 결과와도 비교해야 합니다.

GSM8K에서 다른 학습 방식과 비교하면

모델: Qwen2.5-3B-Instruct, Qwen2.5-7B-Instruct

학습: GSM8K + GRPO. 평가: GSM8K 정답률(%). 같은 크기의 모델끼리 비교합니다.

같은 크기의 모델끼리 비교합니다. 7B 열을 강조했습니다.

학습 방식	3B	7B
BF16 Full	84.4	91.2
BF16 LoRA	76.1	88.1
NF4 QLoRA	76.1	85.0
MXFP4 LoRA	73.4	86.4
QeRL (NVFP4 LoRA)	83.3	88.5
QeRL + AQN (추가 잡음 조절)	83.7	90.8

Qwen2.5-7B-Instruct: QeRL + AQN 90.8%

LoRA 대비 +2.7%p, QLoRA 대비 +5.8%p. Full과의 차이는 -0.4%p입니다.

7B의 MATH 500 성능은 Full과 같았다

모델: Qwen2.5-7B-Instruct

학습: BigMath 난도 3~5 + DAPO. 평가: 아래 수학 4개 벤치마크의 Pass@1(%).

학습 방법	MATH 500	AIME 24	AIME 25	AMC 23	평균
BF16 LoRA	77.0	13.3	10.0	42.5	35.7
QeRL (NVFP4 LoRA)	76.8	13.7	10.0	47.5	37.0
QeRL + AQN	77.4	15.5	10.0	42.5	36.4
BF16 Full	77.4	16.7	10.0	45.0	37.3

AQN 추가 후, MATH 500은 76.8%에서 77.4%로 올랐습니다.

AMC 23은 47.5%에서 42.5%로 낮아졌습니다. 같은 모델에서도 과제 별 효과가 달랐습니다.

BigMath 학습 후, 모델 크기별 평균 성능

모델: Qwen2.5-7B-Instruct, Qwen2.5-14B-Instruct, Qwen2.5-32B-Instruct

학습: BigMath + DAPO. 평가: MATH 500, AIME 24·25, AMC 23의 평균 정확도(%).

상태 또는 학습 방식	7B	14B	32B
BF16, RL 전	28.9	36.0	39.7
NVFP4, RL 전	25.7	34.0	36.7
BF16 LoRA, RL 후	35.7	40.2	42.2
QeRL, RL 후	37.0	40.5	41.4
QeRL + AQN, RL 후	36.4	42.0	45.6
BF16 Full, RL 후	37.3	43.3	46.2

QeRL + AQN의 LoRA 대비 평균 향상: 7B +0.7%p, 14B +1.8%p, 32B +3.4%p

평균은 논문 보고값입니다. AQN이 없는 QeRL보다 7B 평균은 낮았습니다.

32B의 이득은 평가 과제마다 달랐다

모델: Qwen2.5-32B-Instruct

학습: BigMath 난도 4~5 + DAPO. 평가: 수학 4개 벤치마크의 Pass@1(%).

학습 방식	MATH 500	AIME 24	AIME 25	AMC 23
BF16 LoRA	83.6	16.7	13.3	55.0
QeRL	81.6	16.7	15.0	52.5
QeRL + AQN	83.3	16.7	19.2	63.3
BF16 Full	84.0	20.0	23.3	57.5

AMC 23은 Full보다 5.8%p 높지만, AIME 25는 4.1%p 낮습니다.

탐색을 넓혀 얻는 유효한 후보가 과제마다 다를 수 있다는 해석이 가능합니다.

7B에서는 훈련 보상이 더 일찍 상승했다

모델: Qwen2.5-7B-Instruct

학습: BigMath 난도 3~5 + DAPO. 세로축은 훈련 답안의 정답 보상입니다.




Figure 12. BigMath 7B의 훈련 보상

QeRL

~200_{steps}

이후 보상이 빠르게 상승합니다.

BF16 LoRA

500+_{steps}

이후 상승이 뚜렷해집니다.



가능한 이유는 더 넓은 풀이 탐색입니다. 학습률 차이의 영향도 함께 봐야 합니다.

AQN을 추가해도 항상 좋아지지 않는다

모델: Qwen2.5-7B-Instruct, Qwen2.5-14B-Instruct, Qwen2.5-32B-Instruct

BigMath + DAPO로 학습한 뒤, 같은 NVFP4 LoRA에서 AQN 유무에 따른 평균 정확도(%)를 비교합니다.

수학 4개 벤치마크 평균 정확도(%)



탐색의 이득과 기존 풀이를 교란하는 비용이 함께 작용할 수 있습니다.

잡음 감쇠 방식과 어댑터 크기도 비교했다

모델: Qwen2.5-3B-Instruct. GSM8K + GRPO 학습 중 보상을 비교합니다.

추가 잡음의 감쇠 방식




Figure 9. 감쇠 함수 비교

후반부 잡음을 줄이면, 발견한 풀이를 안정적으로 학습하기 쉬워질 수 있습니다.

LoRA rank




Figure 10. rank 16·32·64·128 비교


이 설정에서는 작은 어댑터로도 필요한 정책 변화를 표현한 것으로 보입니다.

모델 저장 크기는 약 61~67% 감소했다

모델: Qwen2.5-7B-Instruct, Qwen2.5-14B-Instruct, Qwen2.5-32B-Instruct

지표: 저장된 모델 크기(GB). 각 모델에서 BF16 LoRA와 QeRL을 비교합니다.

저장된 모델 크기(GB)



Qwen2.5-32B-Instruct

66.8% 감소

62.3 GB에서
20.7 GB 로 줄었습니다.

직접 원인은 가중치당 저장 비트 수의 감소입니다.

이 수치는 학습 중 최고 GPU 메모리 사용량과 다릅니다. KV 캐시와 활성값의 공간도 필요합니다.

총 학습 속도는 LoRA 대비 1.2~1.5배였다

모델: Qwen2.5-7B-Instruct, Qwen2.5-14B-Instruct

조건: H100 80GB 1장. 같은 모델의 BF16 LoRA를 1.0으로 둔 GRPO 총 학습 속도입니다.

모델	방법	배치 2	배치 4	배치 8
7B	QLoRA (NF4)	0.8배	0.8배	0.7배
7B	QeRL (NVFP4)	1.5배	1.4배	1.2배
14B	QLoRA (NF4)	0.9배	0.7배	0.7배
14B	QeRL (NVFP4)	1.4배	1.2배	1.2배

생성은 빨라져도 로그확률 계산과 파라미터 갱신 비용은 남아 있습니다.

롤아웃의 이득은 큰 모델에서 더 컸다

모델: Qwen2.5-Instruct의 3B·7B·14B·32B

조건: H100 80GB 1장, 배치 8. 각 모델에서 답안 생성 처리량(tokens/s)을 비교합니다.

모델	BF16 LoRA	QeRL	처리량 비율
3B	2,226.3	2,271.4	1.02배
7B	1,641.1	2,091.8	1.27배
14B	737.2	1,091.1	1.48배
32B	344.3	688.2	2.00배

이 조건에서는 큰 모델일수록 가중치 전송량 절감의 이득이 컸을 수 있습니다.

“2배”는 이 32B 롤아웃 조건의 결과입니다. 총 학습 배속과 구분해야 합니다.

32B를 H100 한 장에서 학습할 수 있었다

모델: Qwen2.5-32B-Instruct

조건: H100 80GB 1장, GRPO 학습. GC는 활성값을 다시 계산해 메모리를 아끼는 기법입니다.


방법	GC 끄	GC 켜, 배치 2	GC 켜, 배치 8
BF16 LoRA	OOM	OOM	OOM
QeRL	OOM	10.6초/스텝	12.2초/스텝

이 결과가 보여 주는 것은 해당 조건에서의 단일 GPU 학습 가능성입니다.

최종 정확도 실험은 H100 8장으로 학습했습니다. BF16 LoRA가 OOM이므로 총 학습 배속은 계산할 수 없습니다.

생성 속도와 총 학습 속도의 차이

전체 100초 중 생성에 70초를 쓴다고 가정합니다. 생성 속도가 2배면 총 시간은 65초가 됩니다.



설명용 계산 · 실험 수치 아님

1.54배

100초에서 65초

생성 외 작업의 비용이 남기 때문에 전체 속도 향상은 더 작습니다.

학습률 차이도 함께 읽어야 한다

모델: Qwen2.5-7B-Instruct. 학습률별 훈련 보상 곡선을 비교합니다.

QeRL




Figure 16. QeRL의 학습률별 보상

BF16 LoRA




Figure 17. LoRA의 학습률별 보상

주요 실험의 학습률: QeRL 1×10^{-5} , LoRA 5×10^{-6}

잡음의 효과와 더 큰 학습률을 쓸 수 있는 효과가 함께 작용할 수 있습니다.

확인한 결과와 가능한 원인을 구분하면

모델이 좋아졌다는 관측과, 왜 좋아졌는지를 분리한 증거의 강도는 다릅니다.

관측한 결과	가능한 원인 또는 직접 원인	해석의 범위
모델 크기 감소	가중치당 저장 비트 수 감소	모델 크기 수치로 확인
롤아웃 속도 개선	가중치 전송량과 커널 비용 절감	하드웨어·배치·구현에 의존
높은 엔트로피와 보상 상승	새로운 풀이 탐색의 확대	학습률 등 다른 영향도 존재
AQN의 선택적 성능 개선	탐색과 안정적 학습 사이의 균형	과제별 변화의 원인은 미분리

더 강한 인과 검증에는 같은 학습률·생성 예산의 비교와 여러 시드가 필요합니다.

효율을 넘어, 탐색 방식의 변화

가중치를 작게 저장하고,
작은 어댑터를 학습합니다.

오차와 잡음은
더 다양한 탐색을 도울 수 있습니다.

정확도, 탐색의 근거, 실제 시간과 메모리를 함께 읽습니다.

원문으로 이어서 읽기

QeRL 논문 원문 ↗

[Huang 외, 2025 · arXiv:2510.11696v1](#)

공식 구현 ↗

github.com/NVlabs/QeRL

다시 읽을 부분

원리: §3

정확도: Table 1·2

효율: Table 3·5~9

한계: Appendix K

발표자 노트에서 각 슬라이드의 설명과 근거 위치를 확인할 수 있습니다.